

省エネルギー志向の Dynamic-Temperature Distillation: Moment 系列および SENvT 系列の蒸留設計と展望

岡橋 和希

October 16, 2025

1 概要

本稿は、Moment の事前学習モデル $\rightarrow$ Student-Moment, SENvT の事前学習モデル $\rightarrow$ Student-SEnvT の二系列を独立に設計し、それぞれに時間方向の動的温度制御を導入した上で、省エネルギー蒸留を明確な目標として付加する構成を提案する。具体的には、(i) 時刻単位の温度 T_t に基づく distillation に計算コスト正則化を組み込む E-DTD, (ii) T_t からスキップ/縮退 (token/head/step) の確率を決める温度駆動ゲーティング, (iii) 二系列の生徒間で出力を一貫化する二系列一貫性蒸留を新規に導入する。右側 (Reservoir 接続) は展望とし、蒸留で得た温度系列を内部動作の制御信号として再利用する省エネ化の道筋を示す。

2 研究構成

Moment(Teacher) $\rightarrow$ Student-Moment SENvT(Teacher) $\rightarrow$ Student-SEnvT

本稿ではまず左側の二過程 (各教師 $\rightarrow$ 各生徒) の完結設計を行う。右側の Reservoir 接続 (各生徒 $\rightarrow$ Reservoir) は将来拡張とする。

3 関連研究 (位置づけのみ)

知識蒸留における温度付き Softmax は Hinton らに端を発し、学習段階で温度を変える CTKD, サンプル単位で温度を変える DTKD などが報告されている。一方、本稿はこれら既発表機構を「そのまま用いる」のではなく、時刻単位の温度を時系列蒸留の計算配分 (省エネ) に直結させる新規目標を設定する点が異なる。すなわち、温度を「教師分布の滑らかさ調整」だけでなく、蒸留強度・計算量・実行時スキップの制御変数として用いる。

4 Moment 系列：時刻単位 DTD と省エネ拡張

(a) 基本 DTD（時刻 t ごとの温度）

教師／生徒のロジットを $z_T(t), z_S(t)$ とする。教師出力の変動率に基づき

$$T_t = T_0 + \alpha \sigma_t, \quad \sigma_t = \|z_T(t) - z_T(t-1)\|_2, \quad (1)$$

$$L_{\text{DTD}} = \sum_t T_t^2 KL\left(\text{softmax}\left(\frac{z_T(t)}{T_t}\right) \parallel \text{softmax}\left(\frac{z_S(t)}{T_t}\right)\right). \quad (2)$$

(b) 新規：エネルギー正則化付き DTD (E-DTD)

T_t に依存する実行時計算コストの期待値 $\hat{C}_t$ を導入し、蒸留損失に正則化する：

$$\hat{C}_t = \kappa_t C_{\text{full}} + (1 - \kappa_t) C_{\text{skip}}, \quad \kappa_t = \text{sigmoid}(\beta(T_t - \tau)), \quad (3)$$

$$L_{\text{E-DTD}} = L_{\text{DTD}} + \lambda_E \sum_t \hat{C}_t. \quad (4)$$

ここで κ_t はその時刻にどれだけ計算を使うか（keep ratio）を表す連続係数。 T_t が高い（不確実）区間では $\kappa_t \uparrow$ として計算を厚く、 T_t が低い（安定）区間では $\kappa_t \downarrow$ として計算を節約する。 λ_E は省エネの重み。

(c) 新規：温度駆動ゲーティング（step/token/head）

κ_t を用いて時間ステップスキップやトークン／ヘッド縮退を制御する。例えばトークン i の keep 率を

$$\kappa_{t,i}^{\text{tok}} = \text{sigmoid}(\beta_{\text{tok}}(\tau_{\text{tok}} - T_t)), \quad (5)$$

とし、期待計算 $\hat{C}_t = \sum_i \kappa_{t,i}^{\text{tok}} C_{\text{tok}} + \dots$ を $L_{\text{E-DTD}}$ に組み込む。ソフト化（連続化）により勾配伝播可能。これにより温度＝信頼度を直接計算配分に結びつける。

5 SENvT 系列：出力＋特徴蒸留と省エネ拡張

(a) 損失設計

$$L_{\text{out}} = L_{\text{DTD}} \text{ (SEnvT 出力に適用)}, \quad (6)$$

$$L_{\text{feat}} = \sum_{\ell} \|h_T^{(\ell)}(t) - h_S^{(\ell)}(t)\|_2^2, \quad (7)$$

$$L_{\text{total}} = \lambda_1 L_{\text{out}} + \lambda_2 L_{\text{feat}} + \lambda_E \sum_t \hat{C}_t. \quad (8)$$

$h^{(\ell)}$ は層 ℓ の中間表現。 $\hat{C}_t$ は Moment 系列と同様に T_t 由来の計算配分。

(b) 新規: 二系列一貫性蒸留 (Consistency)

Student-Moment と Student-SEnVt の出力に一貫性項を加える:

$$L_{\text{cons}} = \sum_t w_t \text{KL} \left(\text{softmax} \left(\frac{z_{SM}(t)}{\bar{T}_t} \right) \parallel \text{softmax} \left(\frac{z_{SS}(t)}{\bar{T}_t} \right) \right), \quad (9)$$

ここで z_{SM}, z_{SS} は各生徒のロジット, $\bar{T}_t$ は両系列の温度の平均, $w_t = \phi(T_t)$ は温度に応じた重み (例: 不確定区間に弱く, 安定区間に強く)。最終損失は $L_{\text{total}} + \lambda_C L_{\text{cons}}$ 。同一入力に対し両生徒を整合させることで, 後段の Reservoir 接続における入力安定性を高める (省エネにも寄与)。

6 実装フロー (各系列共通の出力蒸留部)

$$z_T(t) \rightarrow \sigma_t \rightarrow T_t \rightarrow \text{softmax} \left(\frac{z_T(t)}{T_t} \right) \xleftrightarrow{\text{KL}} \text{softmax} \left(\frac{z_S(t)}{T_t} \right) \rightarrow \text{backprop}(L_{\text{E-DTD}})$$

更新ごとに κ に基づくスキップ/縮退を適用して実行時計算を調整する。

7 データと評価設計

使用データ: まず SHL で出力蒸留 + E-DTD を試行し, Moment/Chronos 系の公開ベンチ (活動量計/電力/環境/交通) へ拡張。

指標: 精度 (Accuracy/F1, 回帰なら MAE/MAPE) に加え, **エネルギー指標** (1 推論あたり消費電力 [J], Energy-Delay Product) と **実行時計算量** (FLOPs, アテンション head/token 使用率)。

比較: (i) 非蒸留, (ii) 固定温度蒸留, (iii) 時刻 DTD のみ, (iv) **E-DTD (提案)**, (v) E-DTD + Consistency (提案)。

アブレーション: λ_E, β, τ の掃き出し/ゲーティング種別 (step/token/head) / Consistency の有無。

8 新規性

- **新規目標の設定: 省エネルギー蒸留** — 既発表の動的温度を「分布の滑らかさ調整」に留めず, **実行時計算の配分・スキップ制御**に結び付ける目的関数 $L_{\text{E-DTD}}$ を導入。
- **温度駆動コンピュート・ゲーティング** — T_t から連続ゲート κ を生成し, **時間ステップ/トークン/ヘッド単位で計算を抑制**。蒸留と同時に**省エネ最適化**を行う。
- **二系列一貫性蒸留** — Student-Moment / Student-SEnVt の**クロス整合**を温度重み付きで最適化し, 後段処理の安定化と無駄計算の削減を狙う。

注: Dynamic-Temperature 自体は既報があるため (例: CTKD, DTKD), 本稿は**省エネ最適化を組み込む E-DTD と温度駆動ゲーティング/二系列一貫性**で新規性を担保する。

9 展望：Reservoir 接続（右側の二過程）

蒸留で得た温度系列 T_t を Reservoir のリーク率やゲインに再利用：

$$h_{t+1} = (1 - \alpha_t)h_t + \alpha_t f(W_{in}x_t + Wh_t), \quad \alpha_t = \text{sigmoid}(c T_t). \quad (10)$$

高温（不確実）時は更新を抑え，低温（確信）時には更新を促進。省エネと安定性の両立を目指す（本稿では計画段階）。

References

- [1] Hinton, G. et al. Distilling the Knowledge in a Neural Network.
- [2] Li, Z. et al. Curriculum Temperature for Knowledge Distillation. AAAI, 2023.
- [3] Wei, Y. and Bai, L. Dynamic Temperature Knowledge Distillation. arXiv:2404.12711.